IP 智能导师

Smart IP Tutor

产品需求文档（PRD）V2.0

适用平台：康信 IP 平台（service.kangxin.com）

康信 AI+IP 创新挑战赛 · 第 6 小组

文档版本	V2.0（正式版）
编制日期	2026 年 3 月
讨论会	2026 年 3 月 5 日
团队成员	祖云超 · 卢晓勇 · 甄苗苗 · 武景川 · 崔雪键 · 吴雪 · Cathy

0. 文档说明与版本历史

本文档为「IP 智能导师（Smart IP Tutor）」的正式产品需求文档（PRD），版本 V2.0，在 V1.0 初稿基础上全面补充了竞品分析、验收标准、知识库范围、用户权限设计及详细里程碑，作为跨部门统一对齐的主文档，指导产品设计、研发实现与交付验收。

版本	日期	修订人	修订说明
V1.0	2026.02	产品组	PRD 初稿，基础功能框架
V2.0	2026.03	产品组	补充竞品分析、验收标准、知识库范围、权限设计、Agentic RAG 方案、精确里程碑

1. 产品概述

1.1 产品名称与定位

产品名称：IP 智能导师（Smart IP Tutor）

> **产品定位：面向康信 IP 平台（service.kangxin.com）的内置 AI 智能问答与知识辅导模块。基于康信多年积累的行业干货、读书会分享内容与政策库，采用 Agentic RAG 技术，为内部员工及外部客户提供权威、可追溯、结构化的知识产权政策与实务解答。**

核心目标：不做泛化聊天，而是构建：

- 可溯源的专业回答机制——每一条回答均可追溯至具体知识来源
- 可持续扩展的知识体系——支持知识库增量更新，随业务积累持续成长
- 可嵌入平台的长期智能能力模块——低侵入集成，与现有平台无缝共存

1.2 背景与问题

以下三类痛点驱动本产品的立项：

#	痛点	当前影响	本产品解法
1	员工与客户频繁查询各国 IP 法规，查询成本高	每次人工检索耗时 15-30 分钟，准确性无保障	自然语言提问，秒级给出结构化专业回答
2	康信多年积累的读书会资料、案例总结分散，检索效率低	知识资产利用率低，新员工学习成本高	统一入库，语义检索，知识资产真正被用起来
3	通用大模型缺乏 IP 专业语境，存在幻觉与合规风险	回答错误可能导致客户业务损失，合规风险高	基于康信授权知识库+Prompt 约束，可控可追溯

1.3 竞品与替代方案对比

为说明本产品的不可替代性，以下对三类现有方案进行对比：

对比维度	通用 AI（ChatGPT 等）	市面法律 AI（如博思、元典）	IP 智能导师（本产品）	优势说明
IP 专业准确性	中（通用知识）	中高（法条库）	**高（康信专属库）**	基于康信内部实务积累
康信内部知识	✗	✗	✓	核心竞争壁垒
可追溯来源	✗	部分	**✓（V1-V2）**	合规要求必备
平台集成度	需外跳	需外跳	**原生嵌入**	不打断工作流

数据合规	数据出境风险	第三方数据	**康信自有数据**	内部资料安全
定制 Prompt	✗	有限	**✓完全可控**	行业表达规范
使用成本	按量付费	订阅收费	**内部运营成本**	长期 ROI 更优

2. 目标用户与使用场景

2.1 目标用户

用户类型	典型角色	核心需求	使用频率预估
内部用户	专利/商标代理师、法务、客户经理、培训人员	快速查政策、准备客户回复、新员工学习	高频（每日）——内部优先保障
外部用户	企业 IP 负责人、法务人员、创新主体	了解各国申请制度、查询费用与期限规定	中频（每周）——V1 阶段次要保障

2.2 典型使用场景

场景一：政策实时查询　代理师接到客户询问日本特许厅分案新规，直接在平台问答窗口输入问题，15 秒内获得结构化回答，含背景、核心规则、实务提示三层内容，直接用于对客户答复。

场景二：新员工学习　新入职员工学习欧洲专利申请流程，通过多轮追问的方式逐步深入，系统基于读书会资料给出详细讲解，相当于有一位随时在线的资深导师。

场景三：内容辅助　客户经理撰写客户邮件前，通过问答核实政策要点，确保对外沟通内容准确，减少因信息有误导致的来回沟通成本。

3. 核心功能需求

> V1 范围：功能一、二、三为 V1 必须交付项。V2 扩展功能以「V2」标注，不在本次比赛交付范围内。

3.1 功能一：智能问答（核心）

功能描述

用户以自然语言提问，系统基于康信知识库进行 Agentic RAG 检索增强生成，输出结构化、专业化回答。支持多轮对话上下文，能够识别追问中的指代关系，自动补齐上下文条件。

回答结构框架

场景类型	触发关键词示例	回答结构
政策解读	新规定、规则、要求、制度	① 政策背景 ② 核心规则 ③ 生效时间 ④ 实务提示
实务操作	怎么办、如何申请、流程、步骤	① 前提条件 ② 操作步骤 ③ 注意事项 ④ 常见错误
风险提示	风险、注意、可能、影响	① 风险描述 ② 触发条件 ③ 应对建议 ④ 免责声明

其他要求

- 语言：中文优先，预留多语言扩展接口（中/英/日）
- 支持长问题（500 字以内）与多轮追问（上下文窗口最近 N 轮，可配置）
- 回答风格：专业、克制，符合 IP 行业表达规范，不强行发挥
- 无相关内容时：明确提示「暂无匹配资料，建议咨询专业人员」，不生成猜测性内容

3.2 功能二：Agentic RAG 知识检索与溯源

为何选择 Agentic RAG

传统 RAG 仅做单次检索后直接生成，对于复杂的 IP 政策问题（如跨多个国家的比较、涉及多个规则叠加的场景）容易遗漏关键信息。Agentic RAG 在此基础上增加了多步推理与任务拆解能力：系统可以自动判断是否需要分解问题、多次检索不同维度的知识片段，再综合生成回答，显著提升复杂问题的处理准确率。

检索架构

- 向量数据库：语义检索（Top-K，K=3~8 可配置）
- 语义重排（Rerank）：对候选片段按相关性重新排序，减少噪声
- 过滤器：支持按国家/地区、IP 类型（专利/商标/版权）、内容类型过滤
- 多步推理：复杂问题自动拆解为子问题，分别检索后综合作答

知识溯源

- V1：回答注明内容来自哪类文档（如：政策法规 / 读书会资料 / 内部案例）
- V2：展示引用原文片段、文档标题、发布日期、版本信息，可点击查看原文

3.3 功能三：场景化 Prompt 逻辑

Prompt 架构

系统内置分层 Prompt 结构，包含三个必要组件：

- 系统角色定义：「你是康信 IP 平台的专业知识助手，专注于知识产权政策解读与实务辅助」
- 回答边界约束：不确定时保守表达；禁止输出确定性法律结论；内部资料不对外泄露
- 输出格式模板：对应三类场景（政策解读/实务操作/风险提示）的结构化输出模板

免责声明

> 所有回答末尾自动附加：「以上内容仅为知识参考，不构成正式法律意见。具体业务决策请咨询专业代理师或律师。」（文案待法务/业务同事确认）

3.4 功能四：平台集成与交互展现

入口与布局

- 入口位置：service.kangxin.com 右下角悬浮「智能助理」浮窗按钮（卡通风格图标）
- 触发方式：点击展开/收起，不遮挡主界面操作区域
- 浮窗结构：对话区（主体）+ 引用来源区（侧边，V2）+ 模式切换区（顶部）

交互模式

- 专业模式：输出完整三层结构回答，含引用来源标注，适合代理师深度查询
- 简洁模式：输出要点摘要（3 条以内），适合客户经理快速参考

交互细节

- 回车发送；支持 Shift+Enter 换行
- 流式输出（Streaming）：逐字显示，首 token ≤ 3 秒
- 支持复制回答（一键复制全文）
- 支持清空对话
- V2：□/□ 反馈按钮，数据用于回答质量优化

4. 知识库规划

4.1 知识来源范围

知识库分三层，优先级依次递减：

优先级	来源类型	具体内容	覆盖范围	授权状态
P1	**政策法规 / 官方文件**	各国专利局官方公告、专利法条文、PCT 规则、商标法规	中/日/美/欧/PCT	**公开资料，无需额外授权**
P2	**康信内部资料**	读书会分享 PPT/讲稿、内部培训材料、案例总结	根据已有资料确定	**需获得康信授权确认**
P3	**实务干货**	代理师撰写的实务文章、FAQ 汇总、常见问题解答库	视内容而定	**需获得康信授权确认**

> 待确认事项：P2/P3 类文档的使用授权需在本次讨论会上由领导指定对接人，确认可用文档清单。产品组（B）负责整理清单草稿，会后一周内完成。

4.2 数据预处理流程

步骤	环节	处理内容	负责人
1	**文档解析**	支持 PDF / Word / PPT / 纯文本；预留 OCR 扫描件处理能力	后端组（D/E）
2	**清洗与规范化**	去除页眉页脚水印噪声；统一 IP 行业术语（如「分案申请」「优先权」等）	产品组（B）+ 后端组
3	**Chunk 切分**	语义+长度双约束（500~1000 tokens/块）；每块保留来源 metadata	后端组（E）
4	**向量化 Embedding**	批量向量化；支持增量更新（新文档无需重新全量处理）	后端组（C/E）
5	**入库与索引**	写入向量数据库；建立国家/类型/日期过滤索引	后端组（C）

5. 非功能性需求

5.1 性能指标

指标	目标值	底线值	备注
首 token 响应时间	**≤ 2 秒**	≤ 3 秒	用户体验关键指标
单问答总时长	**≤ 10 秒**	≤ 15 秒	含 Agentic 多步检索
并发支持	**≥ 20 并发**	≥ 10 并发	内部使用优先保障
系统可用性	**≥ 99%**	≥ 95%	工作日在线时间
失败重试	**自动重试 2 次**	降级为仅检索不生成	保障基础可用性

5.2 准确性要求

- 回答必须基于已入库知识，不强行发挥或基于模型通用知识生成
- 无匹配内容时：明确返回「暂无匹配资料」，给出建议补充来源
- Case Study 验收目标：从典型 IP 政策问题库（涵盖中/日/美/欧 PCT）中抽取 20 题，业务组评分通过率 ≥ 80%
- 幻觉率监控：上线后持续跟踪，目标将幻觉率控制在 5% 以内

5.3 安全与合规

- 仅使用康信授权知识库与合规数据源，不引入未经授权的外部内容
- 内外部用户权限隔离：外部用户无法检索到内部敏感资料（详见第 6 节）
- 所有回答强制附带「非正式法律意见」免责声明（前端可配置显示形式）
- 禁止生成确定性法律结论（如「该行为一定构成侵权」）
- 日志记录：问题文本、命中片段 ID、模型响应，用于审计与质量优化

6. 用户权限设计

内外部用户在知识访问范围和功能权限上有所区分，确保内部资料安全。

权限维度	内部员工	外部客户（V1）	说明
可访问知识范围	P1 + P2 + P3 全部	P1 公开政策法规	内部资料不对外暴露
专业模式/简洁模式	两种模式均可	仅简洁模式	V2 可开放专业模式给认证客户
对话历史记录	保留（本会话）	不保留	V2 支持登录用户历史
反馈功能（V2）	✓	✓	均可提交回答质量反馈
知识库来源显示	显示来源类型	不显示	保护内部资料信息

> V1 阶段：优先保障内部员工使用，外部客户功能作为次要目标，时间不足时可推迟至 V2。

7. 技术方案概览

7.1 系统架构分层

层级	组件	技术选型
前端层	智能助理悬浮浮窗（Vue.js 组件）；流式输出（SSE）	Vue.js；EventSource API（SSE）
应用层（后端）	会话管理服务；Prompt 编排服务；Agentic RAG 调度服务	Java（Spring Boot）；RESTful API
AI 能力层	Embedding 服务；LLM 推理服务（API 调用）；Rerank 服务	待选：Gemini / OpenAI（需确认合规）
数据与知识层	向量数据库；原始文档存储；结构化 Metadata	待选：pgvector / Milvus / Weaviate

7.2 Agentic RAG 工作流

相比传统 RAG 的单次检索，Agentic RAG 增加了任务规划与多步检索能力，具体流程如下：

```
Step 1  接收用户问题 → 意图识别（政策解读 / 实务操作 / 风险提示）
Step 2  任务规划（复杂问题自动拆解为 2~3 个子问题）
Step 3  逐子问题执行语义检索（Top-K，含 Rerank 重排）
Step 4  合并检索结果 → Prompt 编排（含系统角色 + 回答边界 + 输出模板）
Step 5  LLM 生成回答 → 流式输出至前端 → 附加溯源标注 + 免责声明
```

7.3 接口设计要求

前端 → 后端

- POST /api/chat/query
  - 入参：question（string）, session_id（string）, user_role（internal | external）, mode（professional | simple）
  - 出参：SSE 流式 token / final_answer / source_refs（来源引用）/ disclaimer（免责声明）

后端 → AI 服务

- Embedding API：文档向量化 + 查询向量化
- Rerank API：候选片段重排序
- Chat Completion API：LLM 生成回答（支持流式输出）

7.4 技术栈确认

模块	确定技术	待决策项
前端	Vue.js	—
后端	Java + Spring Boot	—
向量数据库	待定	pgvector / Milvus / Weaviate（本次会议需确认）

Embedding 模型	待定	通义 text-embedding / OpenAI/Gemini（需确认数据合规）
LLM	待定	通义千问 / GPT-4o（需确认 API 预算与合规）
Rerank	待定	Cohere Rerank / BGE-Reranker（本地部署优先）

8. 团队分工

小组	成员	角色	核心任务	主要交付物
产品与 知识中心	Cathy 甄苗苗 崔雪键 吴雪	PM 知识工程师	知识库授权确认与文档清单整理；Prompt 设计调优；原型设计；PRD 维护	PRD、结构化知识库、Prompt 逻辑文档
AI 与 后端开发	卢晓勇 祖云超（AI/数据）	架构师 后端 AI 工程师	向量数据库选型与搭建；Agentic RAG 架构实现；模型 API 接入；接口开发	后端源码、API 文档、数据库 Schema
前端开发与 UI 设计	武景川	前端 UI/UX 品牌	浮窗交互设计；Vue 组件开发；流式输出实现；视觉规范制定	前端源码、UI 规范手册、高保真原型

9. 项目里程碑与时间计划

比赛 Demo Day 分两批：第一批 2026 年 4 月底，第二批 2026 年 6 月底。第 6 小组目标参加第一批。

阶段	名称	目标时间	关键动作	交付物
T1	**筹备期**	3 月上旬（当前）	确定技术栈；完成知识库授权确认；整理知识源文档清单；搭建开发环境	知识源清单（含授权状态） 技术选型决策文档
T2	**设计期**	3 月中旬	完成 UI 高保真原型；后端搭建 RAG 基础架构（Embedding + 向量库入库逻辑）；Prompt 模板 V1 完成	PRD V2.0（本文档） UI 原型 RAG 基础框架
T3	**开发期**	3 月下旬 ~4 月上旬	前后端并行开发；首批知识入库；进行 RAG 精度测试（20 题 Case Study）；前后端联调	初版可运行代码 向量库（首批） 联调测试报告
T4	**调优期**	4 月中旬	针对日本特许厅分案新规等具体场景进行 Case Study 深度调优；性能压测；UI 细节打磨	调优测试报告 性能测试报告
T5	**交付期**	4 月下旬（Demo Day）	整合全套代码；撰写技术文档；向运营组提交成果；准备 Demo 演示材料	全套代码 技术文档 Demo 演示 PPT

10. 验收标准

以下标准作为 Demo Day 演示与评审的验收依据，也是各子组开发对齐的终态目标。

#	验收维度	具体标准	评判方式	负责确认
1	**功能完整性**	智能问答、知识溯源、Prompt 逻辑三大功能均可正常运行	现场演示	评审组
2	**问答准确率**	从典型 IP 政策题库中抽取 20 题，业务组评分通过率 ≥ 80%	Case Study	业务组打分
3	**性能达标**	首 token 响应 ≤ 3 秒，单问答总时长 ≤ 15 秒	压测工具验证	后端组
4	**专业表达规范**	回答语言符合 IP 行业规范，无明显错误术语或不专业表达	业务组主观评分	业务组
5	**平台集成稳定**	浮窗入口正常，Streaming 流式输出无中断，错误有提示	功能测试	前端组
6	**合规边界**	不输出确定性法律结论；内部资料不泄露；免责声明正常显示	人工检查	产品组

11. 待决策事项（本次讨论会需确认）

> 以下事项需在 2026 年 3 月 5 日 讨论会上明确答复，以确保 T1 阶段顺利收尾、T2 阶段正常启动。

#	决策事项	需要领导支持	影响节点	当前状态
D1	知识库可用文档授权范围确认（P2/P3 类）	指定知识库对接人	T1 收尾	待确认
D2	大模型 API 预算与合规确认（通义/GPT 选型）	明确预算来源与审批流程	T1 收尾	待确认
D3	向量数据库最终选型（pgvector/Milvus/Weaviate）	技术可行性支持	T2 启动	待确认
D4	免责声明文案由谁起草并审核	法务或资深业务同事配合	T2 启动	待确认
D5	V1 是否覆盖外部客户（还是仅内部员工）	产品范围决策	T3 开发	建议仅内部

附录 A | 技术需求说明（Tech PRD）

本附录面向研发、架构、AI 工程团队，实现层面优先级高于业务表述。

A1. 向量数据库 Schema

字段名	类型	说明
chunk_id	string (UUID)	知识片段唯一标识
doc_id	string	所属原始文档 ID
source_type	enum	policy_law / internal_training / practice_note
country	string	适用国家/地区代码（CN/JP/US/EP/PCT）
ip_type	enum	patent / trademark / copyright / general
content	text	知识片段原文（500~1000 tokens）
embedding	vector(1536)	向量化表示
doc_title	string	文档标题
doc_date	date	文档发布/更新日期
is_internal	boolean	是否为内部资料（控制外部用户访问权限）

A2. Prompt 模板结构

> 系统 Prompt 必须包含以下三层，缺一不可：

Layer 1：系统角色定义

「你是康信 IP 平台的专业知识助手（Smart IP Tutor），专注于知识产权政策解读、申请实务辅助和制度教学。你的回答必须基于提供的知识库内容，使用规范的 IP 行业表达方式，不允许输出通用知识或个人推测。」

Layer 2：回答边界约束

- 当检索结果置信度低时，使用「根据现有资料，暂无完全匹配的内容，建议进一步核实」
- 禁止输出「该行为一定构成侵权/违法」等确定性法律结论
- 禁止引用 is_internal=true 的内容回复 user_role=external 的请求

Layer 3：输出格式模板（以政策解读为例）

政策背景：[简要说明该政策的来源与适用范围]

核心规则：[条目式列出关键规定，不超过 5 条]

实务提示：[代理师视角的注意事项与操作建议]

参考来源：[来源类型标注，V2 扩展为具体文档链接]

以上内容仅供参考，不构成正式法律意见。

A3. 日志与监控指标

指标	记录内容	用途
问答日志	问题文本、	用量统计、安全审计

	session_id、user_role、时间戳	
检索命中日志	命中 chunk_id 列表、Top-K 分数	检索精度优化
响应质量日志	首 token 时间、总时长、是否降级	性能监控
用户反馈（V2）	□/□、可选文字评论	回答质量优化、幻觉识别

A4. 技术交付清单

- 后端服务源码（Java + Spring Boot，含 Agentic RAG 调度逻辑）
- 前端 Vue 组件源码（浮窗 + 对话界面 + 流式输出）
- Prompt 模板配置文件（YAML/JSON，支持热更新）
- 向量库 Schema 定义文件
- API 接口文档（OpenAPI 3.0 格式）
- 知识库初始化脚本（文档解析 + Chunk + Embedding 批处理）
- 部署说明文档（环境依赖、配置项、启动步骤）